



UNIVERSIDADE FEDERAL DE ITAJUBÁ

Banco de Dados II

COM 231

Indexação

Vanessa Cristina Oliveira de Souza

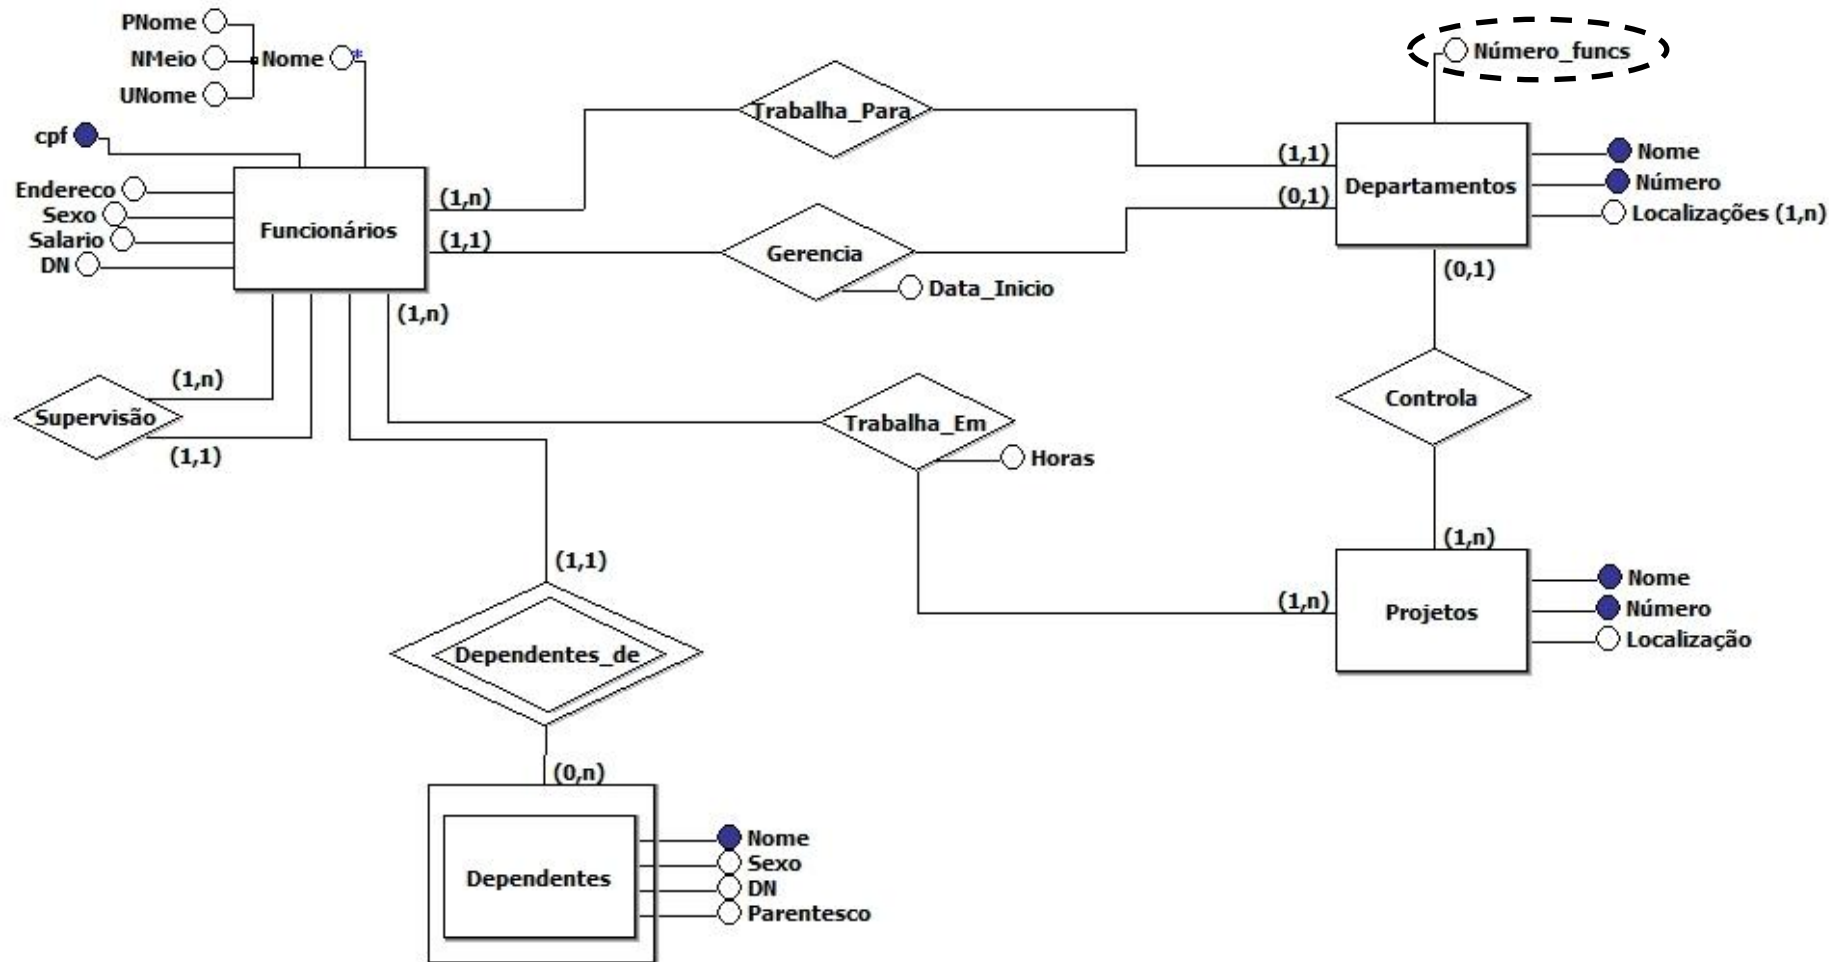


Introdução

- No nível conceitual ou lógico, o banco de dados no modelo relacional, foi visto como uma coleção de tabelas.
- O modelo lógico de um banco de dados é o nível correto para o usuário do banco de dados focalizar.

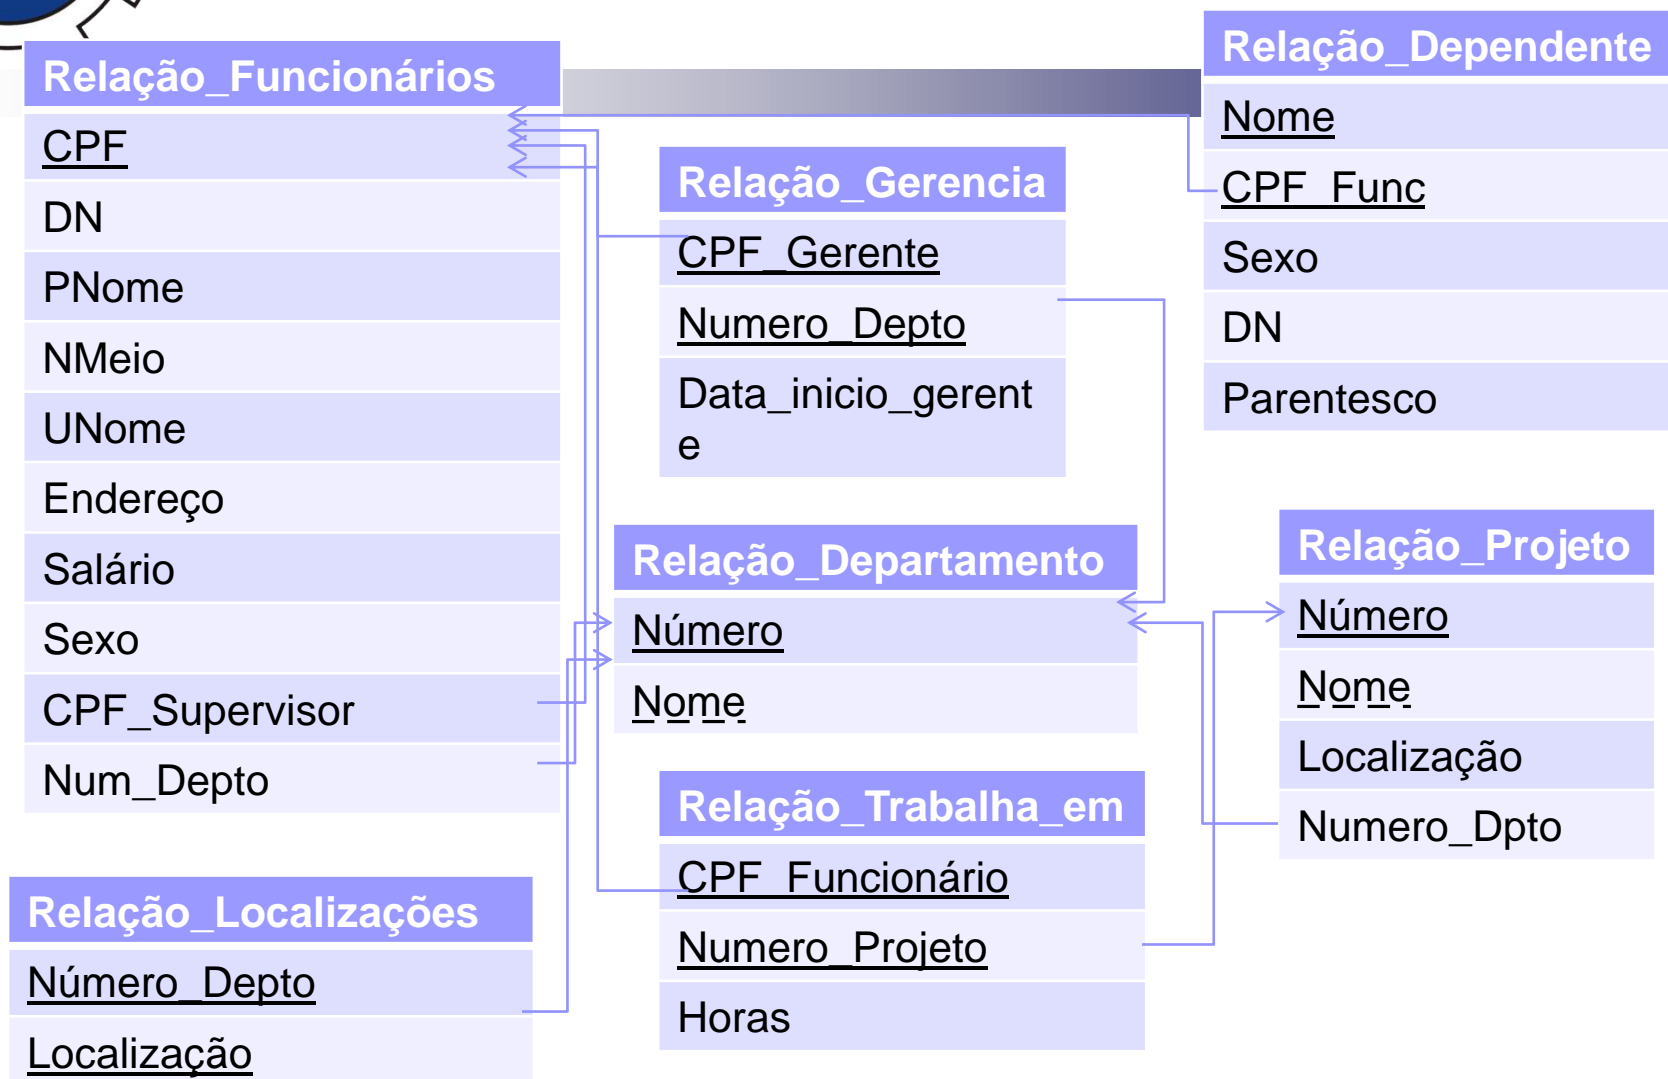


Mapeamento MER - MR





Mapeamento MER - MR





Mapeamento MER – MR

Outra 'nomenclatura'

Relacao_Departamentos(Número, Nome)

Relacao_Localizações (Numero_Depto, Localização)

Num_Depto REFERENCIA Relacao_Departamentos (Numero)

Relacao_Funcionarios(CPF, DN, Pnome, Nmeio, Unome, Endereço, Salário, Sexo, CPF_Supervisor, Num_Depto)

CPF_Supervisor REFERENCIA Relacao_Funcionarios (CPF)

Num_Depto REFERENCIA Relacao_Departamentos (Numero)

Relacao_Dependentes(CPF_Func, Nome, DN, Sexo, Parentesco)

CPF_Func REFERENCIA Relacao_Funcionarios (CPF)

Relacao_Gerencia (CPF_Func, Numero_Depto, Data_inicio_gerente)

CPF_Func REFERENCIA Relacao_Funcionarios (CPF)

Num_Depto REFERENCIA Relacao_Departamentos (Numero)



Modelo Físico

```
CREATE DATABASE aulaIndice;
```




Programas > PostgreSQL > 10 > data > base

	Nome	Data de
OID {	1	26/03/2
	12937	26/03/2
	12938	26/03/2
	16393	26/03/2
	18714	26/03/2



Modelo Físico

```
CREATE DATABASE aulaIndice;
```



Programas > PostgreSQL > 10 > data > base

Nome

Data de

OID

- 1
- 12937
- 12938
- 16393
- 18714

```
C:\Program Files\PostgreSQL\10\bin>oid2name -U postgres
Password:
All databases:
  Oid      Database Name  Tablespace
-----
 18714     aulaIndice     pg_default
 16393     postgis_24_sample pg_default
 12938     postgres       pg_default
 12937     template0      pg_default
 1         template1      pg_default
```



Modelo Físico

```
CREATE TABLE departamento(  
    numeroDepto int,  
    nomeDepto varchar(30) not null,  
    primary key(numeroDepto)  
);
```




Modelo Físico

```
CREATE TABLE departamento(  
    numeroDepto int,  
    nomeDepto varchar(30) not null,  
    primary key(numeroDepto)  
);
```



```
select pg_relation_filepath('departamento')
```

Output Explain Messages Query History

pg_relation_filepath
text

base/18714/18715



Modelo Físico

```
INSERT INTO departamento VALUES (1, 'Recursos Humanos');  
INSERT INTO departamento VALUES (2, 'Producao');  
INSERT INTO departamento VALUES (3, 'Financeiro');  
INSERT INTO departamento VALUES (4, 'Almoxarifado');
```

- Organização de registros em arquivos
 - ☐ Organização de arquivos em *heap*
 - ☐ Organização sequencial de arquivos
 - ☐ Organização de arquivos de *hashing*




Registros Lógicos X Registros Físicos

- O registro **lógico** corresponde às instâncias (objetos) do mundo real, cujos atributos são representados pelos campos. Estes registros é que são manipulados pelos programas (sistemas) de aplicação.
- O registro **físico** corresponde à organização física onde as informações são armazenadas (no HD, setores).



Organização de Arquivos

- Organizar um arquivo significa relacionar (mapear) a estrutura lógica e a estrutura física de um arquivo.



Maapeamento entre estrutura física e lógica.



Organização de Arquivos

- A organização de arquivo trata do arranjo ou a forma de distribuição dos registros dentro do arquivo, objetivando **agilizar o processo de armazenamento e recuperação de dados.**



Modelo Físico

- Organização de arquivos em *heap*
 - Heap é sinônimo de aleatório, desordenado.
 - Um registro pode ser colocado em qualquer lugar no arquivo onde exista espaço para acomodá-lo
 - Não existe ordenação dos registros dentro do bloco
 - Normalmente existe um único arquivo para cada relação



Modelo Físico

- Organização sequencial de arquivos
 - Os registros são armazenados em ordem sequencial, de acordo com o valor da “chave de busca” de cada registro
 - Em geral, a chave de busca é a chave primária da relação




Modelo Físico

- Organização de arquivos de Hashing
 - Uma função de hash é calculada sobre algum atributo de cada registro.
 - O resultado da função de hashing especifica em que bloco do arquivo o registro deve ser colocado.



Modelo Físico - PostgreSQL

```
INSERT INTO departamento VALUES (1, 'Recursos Humanos');  
INSERT INTO departamento VALUES (2, 'Producao');  
INSERT INTO departamento VALUES (3, 'Financeiro');  
INSERT INTO departamento VALUES (4, 'Almoxarifado');
```



Data Output			Explain	Messages	Query History
	numeroDepto [PK] integer	nomeDepto character varying (30)			
1	1	Recursos Humanos			
2	2	Producao			
3	3	Financeiro			
4	4	Almoxarifado			



Modelo Físico – PostgreSQL

- Cada tabela é armazenada como um array de páginas (blocos) de tamanho fixo (normalmente 8kb).
- Na tabela, todas as páginas são logicamente equivalentes (mesma estrutura).
- A estrutura utilizada para armazenar uma tabela é um ***heap file***.



Modelo Físico – PostgreSQL

Data Output Explain Messages Query History

	numeroDepto [PK] integer	nomeDepto character varying (30)
1	1	Recursos Humanos
2	2	Producao
3	3	Financeiro
4	4	Almoxarifado

PostgreSQL > 10 > data > base > 18714

Pesquisar 18714

Nome	Data de modificaç...	Tipo	Tamanho
12790_vm	26/03/2018 11:27	Arquivo	0 KB
12790	26/03/2018 11:27	Arquivo	0 KB
12792	26/03/2018 11:27	Arquivo	8 KB
12793	26/03/2018 11:27	Arquivo	8 KB
12793_fsm	26/03/2018 11:27	Arquivo	24 KB
12793_vm	26/03/2018 11:27	Arquivo	8 KB
12795	26/03/2018 11:27	Arquivo	0 KB
12797	26/03/2018 11:27	Arquivo	8 KB
12798	26/03/2018 11:27	Arquivo	8 KB
12798_fsm	26/03/2018 11:27	Arquivo	24 KB
12798_vm	26/03/2018 11:27	Arquivo	8 KB
12800	26/03/2018 11:27	Arquivo	0 KB
12802	26/03/2018 11:27	Arquivo	8 KB
12803	26/03/2018 11:27	Arquivo	0 KB
12805	26/03/2018 11:27	Arquivo	0 KB
12807	26/03/2018 11:27	Arquivo	8 KB
18715	26/03/2018 11:52	Arquivo	8 KB



Modelo Físico – PostgreSQL

aulaIndice on postgres@PostgreSQL 10

```
1 select ctid, * from departamento;
```

Data Output Explain Messages Query History

	ctid tid	numerdepto integer	nomedepto character varying (30)
1	(0,1)	1	Recursos Humanos
2	(0,2)	2	Producao
3	(0,3)	3	Financeiro
4	(0,4)	4	Almoxarifado



Modelo Físico – PostgreSQL

```
DELETE FROM departamento;
```

```
INSERT INTO departamento VALUES (2, 'Producao');
```

```
INSERT INTO departamento VALUES (1, 'Recursos Humanos');
```

```
INSERT INTO departamento VALUES (4, 'Almoxarifado');
```

```
INSERT INTO departamento VALUES (3, 'Financeiro');
```



Modelo Físico – PostgreSQL

```
DELETE FROM departamento;
```

```
INSERT INTO departamento VALUES (2, 'Producao');  
INSERT INTO departamento VALUES (1, 'Recursos Humanos');  
INSERT INTO departamento VALUES (4, 'Almoxarifado');  
INSERT INTO departamento VALUES (3, 'Financeiro');
```




```
8  
9 SELECT ctid, * from departamento;
```

Data Output Explain Messages Query History			
	ctid tid	numerdepto integer	nomedepto character varying (30)
1	(0,5)	2	Producao
2	(0,6)	1	Recursos Humanos
3	(0,7)	4	Almoxarifado
4	(0,8)	3	Financeiro



Modelo Físico – PostgreSQL



O PostgreSQL usa tabelas Heap



Arquivos Sequenciais


- Em um arquivo sequencial, os registros são dispostos **ordenadamente**, obedecendo à sequência determinada por uma chave primária, chamada de chave de ordenação

EMPREGADO

Chave de pesquisa: 1030

Matricula	Nome	Idade	Salário
3	Ademar	32	5000
5	Roberto	25	7500
10	Gerson	43	6000
12	Yeda	23	9000
30	Bernardo	21	4500
50	Ângela	29	5000

Chave de ordenação





Arquivos Sequenciais

- Para permitir uma recuperação rápida de registros na ordem da chave de busca, os registros são encadeados por ponteiros.
- O ponteiro em cada registro aponta para o próximo registro na ordem da chave de busca.



Arquivos Sequenciais

1	3	Ademar	32	5000
2	5	Roberto	25	7500
3	10	Gerson	43	6000
4	12	Yeda	23	9000
5	30	Bernardo	21	4500
6	50	Ângela	29	5000

Overflow



Arquivos Sequenciais

- Vantagem: Acesso sequencial de um conjunto de dados é o mais rápido.
- Útil quando é preciso processar quase todos os elementos.
- Desvantagens: Inclusão e Exclusão é extremamente custosa.



Arquivos Sequenciais

Exemplo de Inserção

3	Ademar	32	5000
5	Roberto	25	7500
10	Gerson	43	6000
12	Yeda	23	9000
30	Bernardo	21	4500
50	Ângela	29	5000
15	Vanessa	28	6000

Overflow

Inserir o registro de chave de ordenação 15.




UNIVERSIDADE FEDERAL DE ITAJUBÁ

INDEXAÇÃO



Indexação – Problema





Indexação – Problema

- Tempo para encontrar o livro aumenta significativamente com o número de livros que se tem na biblioteca em questão.
- Solução:
 - Um catálogo, organizado de alguma forma (por autor, por título, ...) que diga onde encontrar o livro na prateleira.



Índices

- Um índice permite localizar um registro sem ter que examinar mais que uma pequena fração dos registros possíveis;
- O(s) campo(s) cujos valores o índice se baseia formam a **chave de pesquisa**;



Índices

- Índices são, portanto, **estruturas de dados auxiliares** cujo único propósito é tornar mais **rápido** o acesso a registros baseados em certos campos, chamados campos de indexação.



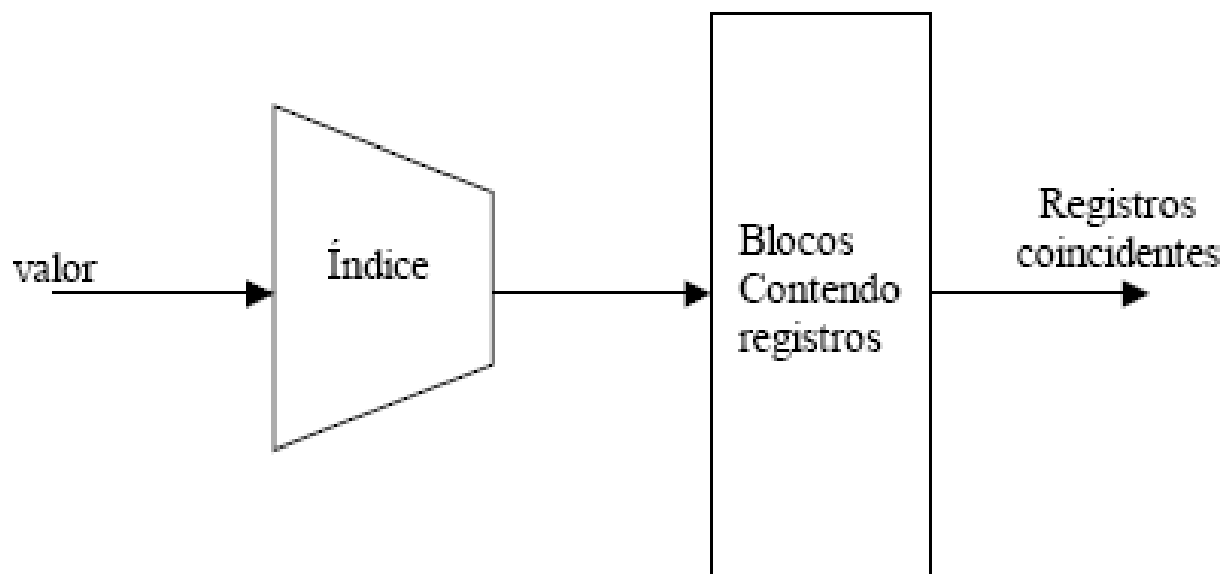
Índices

- Cada índice é formado pelo valor de um atributo chave do registro e pela sua localização física no interior do arquivo.
- A estrutura com a tabela de índices é também armazenada e mantida em disco.



Índices

- Cada estrutura de índice está associada a uma chave de busca particular.





Tipos básicos de Índices

- Ordenados

- ☐ Baseiam-se na ordenação dos valores.

- Hash

- ☐ Baseiam-se na distribuição uniforme dos valores determinados por uma função (função de hash).



Classificação de Índices Ordenados

- Considerando a quantidade de entradas
 - ☐ Denso
 - ☐ Esparso
- Considerando a organização do arquivo
 - ☐ Primário
 - ☐ Clustering
 - ☐ Secundário
- Considerando os níveis de indireccionamento
 - ☐ Mononível
 - ☐ Multinível



UNIVERSIDADE FEDERAL DE ITAJUBÁ

ÍNDICES ORDENADOS

DENSO X ESPARSO




Índices sobre arquivos sequenciais

- Os ponteiros em um arquivo de índices podem se referir a **cada registro** do arquivo ou a um **bloco de disco**, originando dois tipos de índices:
 - ☐ Índice denso
 - ☐ Índice esparsos



Índice Denso

- Há uma entrada no índice para cada valor de chave que ocorre em um registro de dados.




Esse registro de índice contém o valor da chave de busca e um ponteiro para o registro.



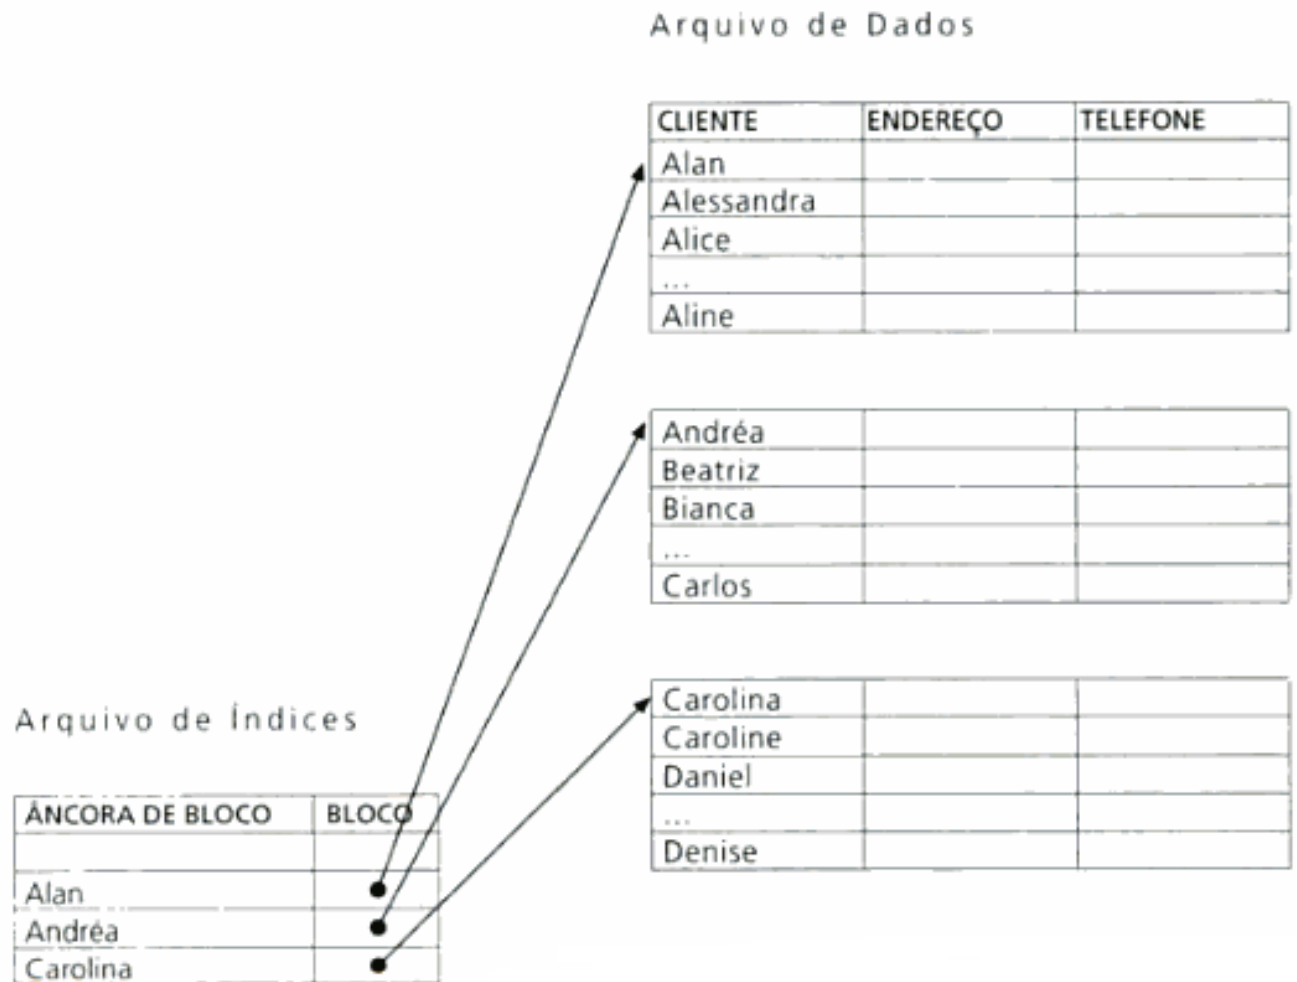
Índice Esperso

- Há uma entrada no índice apenas para alguns valores de chave (um para cada bloco).
- Para localizar um registro com chave K, procura-se a entrada E do índice com o maior valor de chave menor ou igual a K e pesquisa-se o arquivo a partir do registro apontado por E.





Índice Esperso





Índice Esparso X Índice Denso

- Um índice esparso utiliza menos espaço para armazenamento ao custo de um tempo um pouco maior para encontrar um registro dada sua chave.
- No índice esparso, inserções e remoções são menos custosas quando comparadas ao índice denso.



UNIVERSIDADE FEDERAL DE ITAJUBÁ

ÍNDICES ORDENADOS

PRIMÁRIO X CLUSTERING X SECUNDÁRIO



Índice Primário

- No arquivo sequencial, um campo chave é usado para ordenar fisicamente os registros de arquivos em disco.
- Se a chave de ordenação for um campo exclusivo (sem duplicatas), então o índice é chamado de **Índice Primário**.



Índice Primário

- A chave de busca de um índice primário é **usualmente** a chave primária.



Índice Primário

■ Vantagens

- ☐ Economia de acesso aos blocos
- ☐ Busca binária

■ Desvantagem

- ☐ Inclusão e remoção de registros



Índices primários em geral são esparsos

(o número de entradas é
igual ao número de blocos do arquivo de dados)



Índice Primário Esperso

Arquivo de Dados

CLIENTE	ENDEREÇO	TELEFONE
Alan		
Alessandra		
Alice		
...		
Aline		

Andréa		
Beatriz		
Bianca		
...		
Carlos		

Carolina		
Caroline		
Daniel		
...		
Denise		

Arquivo de Índices

ÂNCORA DE BLOCO	BLOCO
Alan	
Andréa	
Carolina	



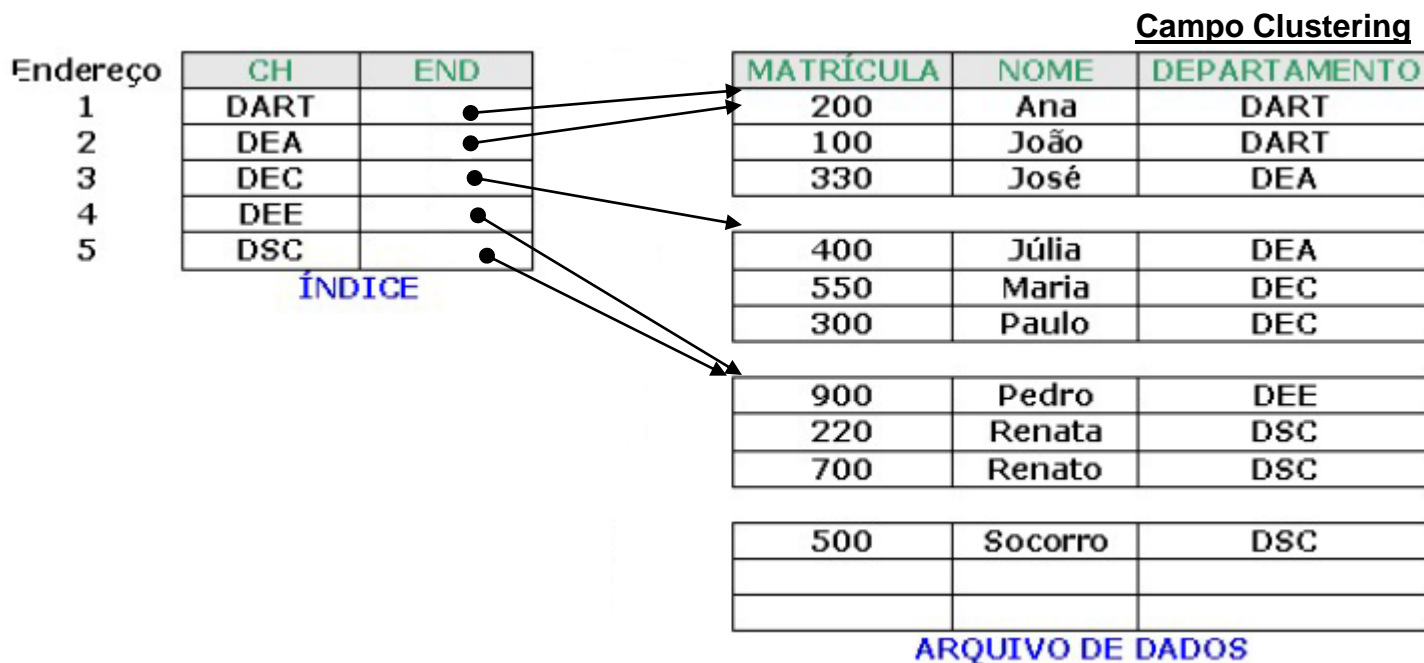


Índice Clustering

- Se a chave de ordenação for um campo não chave (com duplicatas), então o índice é chamado de **Índice Clustering**.
- Existe uma entrada no índice clustering para cada valor distinto do campo clustering.
- O índice contém o valor e um ponteiro para o primeiro bloco no arquivo de dados que possua um registro com aquele valor para seu campo clustering.



Índice de Clustering



No **Índice de Cluster** os registros de um arquivo são fisicamente ordenados por um campo de ordenação que permite duplicatas.



Índices de clustering são esparsos

(o número de entradas é igual ao número de valores distintos do atributo de clustering)



Índice de Clustering

- Vantagens

- ☐ Economia de acesso aos blocos

- Desvantagem

- ☐ Inclusão e remoção de registros



Índices sobre arquivos sequenciais

- Um arquivo pode possuir, no máximo, um índice primário ou um índice de clustering, **porém não ambos.**
- Porque um arquivo pode possuir, no máximo, um campo de ordenação física.



Índice Secundário

- Frequentemente desejamos ter vários índices em uma relação, a fim de facilitar consultas variadas.
- Um terceiro tipo de índice, chamado de índice secundário, pode ser especificado sobre qualquer campo não-ordenado de um arquivo.
- Um arquivo pode possuir diversos índices secundários, além de seu método de acesso principal.



Índice Secundário

- Um índice secundário é um índice cuja chave não é aquela da ordem sequencial do arquivo.
- Portanto, a diferença entre índice secundário e índice primário está no fato de que o índice secundário não determina a colocação de registros no arquivo de dados.



Índices secundários são
sempre densos!!!

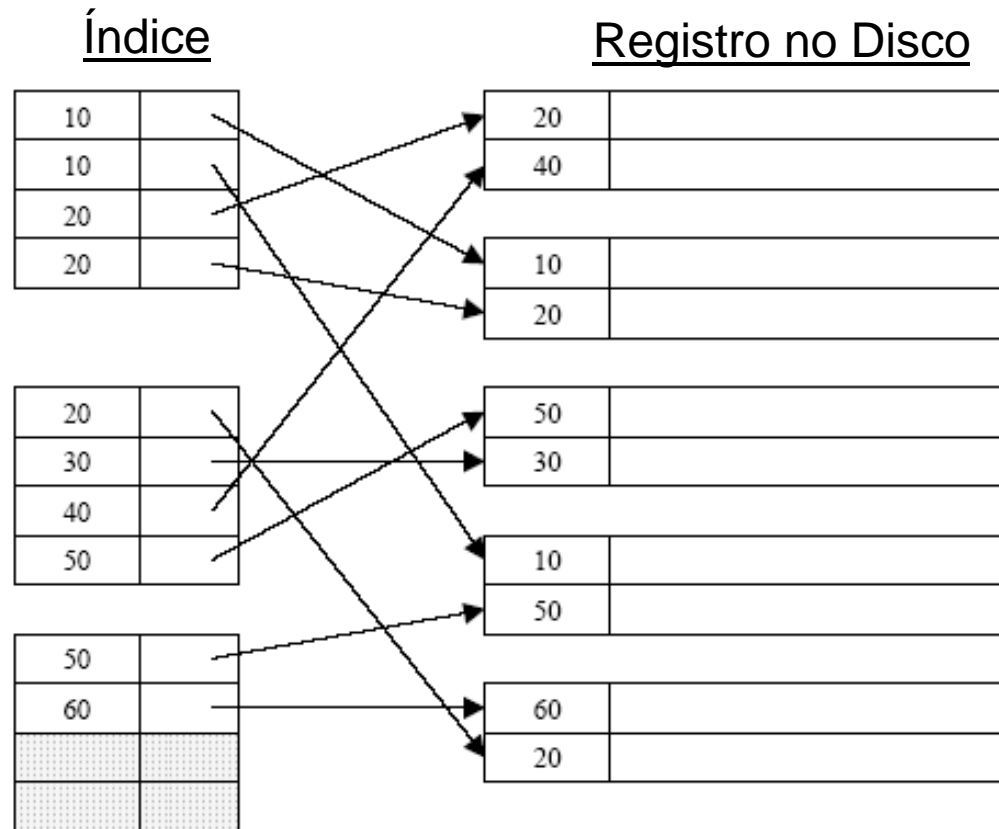


Projeto de índices secundários

- Um índice secundário é um índice denso, normalmente com duplicatas.
- O índice consiste em pares chave-ponteiro.
- Os pares no arquivo de índices são classificados pelo valor da chave.



Índices Secundários - Exemplo



- Os dados não estão classificados pela chave de pesquisa.
- As chaves no arquivo de índices estão classificadas.



Modelo Físico – PostgreSQL

```
DELETE FROM departamento;
```

```
INSERT INTO departamento VALUES (2, 'Producao');
```

```
INSERT INTO departamento VALUES (1, 'Recursos Humanos');
```

```
INSERT INTO departamento VALUES (4, 'Almoxarifado');
```

```
INSERT INTO departamento VALUES (3, 'Financeiro');
```



```
8  
9 SELECT ctid, * from departamento;
```

Data Output Explain Messages Query History

	ctid tid	numerdepto integer	nomedepto character varying (30)
1	(0,5)	2	Producao
2	(0,6)	1	Recursos Humanos
3	(0,7)	4	Almoxarifado
4	(0,8)	3	Financeiro



Modelo Físico – PostgreSQL

```
CREATE TABLE cep.log_logradouro
(
  log_nu_sequencial integer NOT NULL DEFAULT 0,
  ufe_sg character varying(2) COLLATE pg_catalog."default" NOT NULL,
  loc_nu_sequencial integer NOT NULL DEFAULT 0,
  log_no character varying(70) COLLATE pg_catalog."default" NOT NULL,
  log_nome character varying(125) COLLATE pg_catalog."default" NOT NULL,
  bai_nu_sequencial_ini integer NOT NULL DEFAULT 0,
  bai_nu_sequencial_fim integer DEFAULT 0,
  cep character varying(16) COLLATE pg_catalog."default" NOT NULL,
  log_complemento character varying(100) COLLATE pg_catalog."default",
  log_tipo_logradouro character varying(72) COLLATE pg_catalog."default",
  log_status_tipo_log character varying(1) COLLATE pg_catalog."default" NOT NULL,
  log_no_sem_acento character varying(70) COLLATE pg_catalog."default" NOT NULL,
  ind_uop character varying(1) COLLATE pg_catalog."default",
  ind_gru character varying(1) COLLATE pg_catalog."default",
  temp character(8) COLLATE pg_catalog."default",
  CONSTRAINT log_logradouro_pkey PRIMARY KEY (log_nu_sequencial)
)
```

```
SELECT * FROM pg_indexes WHERE tablename = 'log_logradouro';
```

schemaname name	tablename name	indexname name
cep	log_logradouro	log_logradouro_pkey
indexdef text		
CREATE UNIQUE INDEX log_logradouro_pkey ON cep.log_logradouro USING btree (log_nu_sequencial)		



Modelo Físico – PostgreSQL

- Se a tabela *heap* não ordena os dados fisicamente pela chave primária, como se dá o índice de chave primária?
 - Arquivos Heap são listas de registros **não ordenados** de tamanho variado.
 - Uma vez que não há ordenação, para localizar uma informação em um Heap é necessário realizar sempre um “*table scan*”.
 - Heap é uma tabela **sem índice clusterizado** (esparso)
 - O índice é do tipo UNIQUE
 - Todo índice UNIQUE é secundário



Modelo Físico – MySQL INNODB

```
mysql> show indexes from departamento \G;
***** 1. row *****
      Table: departamento
    Non_unique: 0
      Key_name: PRIMARY
  Seq_in_index: 1
  Column_name: numeroDepto
    Collation: A
  Cardinality: 0
      Sub_part: NULL
        Packed: NULL
          Null:
    Index_type: BTREE
      Comment:
  Index_comment:
1 row in set (0.00 sec)
```




Modelo Físico – MySQL INNODB

```
INSERT INTO departamento VALUES (2, 'Producao');  
INSERT INTO departamento VALUES (1, 'Recursos Humanos');  
INSERT INTO departamento VALUES (4, 'Almoxarifado');  
INSERT INTO departamento VALUES (3, 'Financeiro');
```

```
mysql> Select * from departamento;  
+-----+-----+  
| numeroDepto | nomeDepto |  
+-----+-----+  
|          1 | Recursos Humanos |  
|          2 | Producao |  
|          3 | Financeiro |  
|          4 | Almoxarifado |  
+-----+-----+  
4 rows in set (0.00 sec)
```



Exercícios

- Considere uma relação com 1.000.000 registros (ou tuplas) que cabem dez a dez em um bloco de 4.096 bytes.
 - a) Qual é o espaço necessário para os dados?
 - b) Se o campo da chave tem 32 bytes e um ponteiro 8 bytes.
 - a) Quantos pares chave-ponteiro cabem em um bloco?
 - b) Qual o espaço ocupado por um índice denso para esta relação?
 - c) E se um índice esparsa for utilizado, qual o espaço gasto pelo índice?



Resumo Importante!

- Utilizando arquivos sequenciais:
 - Existe índice primário (esparso) para a chave primária da tabela
 - Existe índice secundário (denso) para os demais campos
- Utilizando arquivos heaps:
 - Existe apenas índice secundário, mesmo para a chave primária
- Utilizando arquivos hash:
 - Existe apenas índice secundário, mesmo para a chave primária
- Em todos os casos, o comando SQL de CREATE ÍNDEX só cria índice SECUNDÁRIO.